

MODUL (1)

PRAKTIKUM WEEK-3

STATISTIKA DASAR & REGRESI LINEAR

Big Data & Data Analytics

Updated Modul: 15 September 2025

By **R&D Team SCBD Laboratory 2025** (Nikoleta Kinanthi Becik Widyoraharjo)

Chief of SCBD Laboratory: Prof. Dr. Andry Alamsyah, S.Si., M.Sc.

Coordinator of Laboratory: Dian Puteri Ramadhani, S.M., M.M



Modul Week 3: Statistika Dasar, Visualisasi, dan Regresi Linear

TUJUAN PRAKTIKUM 1 (Week 3 Perkuliahan)

Pada praktikum ke-1 Mata Kuliah Big Data dan Data Analytics, kita akan mengenal Google Colaboratory (*online browser-based platform*) dan bahasa pemrograman Python. Di sini, kita akan mempelajari konsep data mining dan data science, jenis-jenis data, sumber data, serta menentukan model statistik deskriptif dasar untuk analisis big data. Selain mempelajari Statistika Deskriptif dasar, kita juga akan belajar **visualisasi data**, **regresi linear sederhana**, dan **berganda** menggunakan Python.

1. MENGENAL KONSEP DATA

1.1 Pengertian Data

Data adalah informasi, terutama fakta atau angka, dikumpulkan untuk diperiksa dan dipertimbangkan, serta digunakan untuk membantu pengambilan keputusan. Agar data tersebut dapat digunakan menjadi sebuah informasi, perlu cara khusus untuk mengumpulkannya. Dasarnya, metode pengumpulan data terbagi menjadi dua, yaitu data **kuantitatif** dan **data kualitatif**.

- a) **Kuantitatif (numerik)**: data berwujud angka yang bisa didapat dari sebuah pengukuran atau perhitungan, contoh: tinggi badan, berat badan, usia. Data numerik ini dapat dijabarkan lagi menjadi data diskrit dan kontinu.
- b) **Kualitatif (kategorikal)**: data yang dapat dikelompokkan dan terbagi berdasarkan karakteristik atau ciri khasnya masing-masing. Data kategorikal ini dapat dijabarkan menjadi nominal dan ordinal.

1.2 Konsep Data Mining

Data mining adalah proses memilah kumpulan data yang besar untuk mengidentifikasi pola dan hubungan yang dapat membantu memecahkan masalah bisnis melalui analisis data. Proses data mining ini melibatkan beberapa langkah mulai dari pengumpulan sampai visualisasi untuk menggambarkan informasi dari *big data*.

- a) **Pengumpulan data**
- b) **Persiapan data**
- c) **Memilih teknik data mining**

d) Analisis dan interpretasi data

1.3 Jenis-Jenis Data

a) Data terstruktur

Data yang disusun dengan rapi dan diatur sedemikian rupa sehingga memiliki format atau bentuk yang tetap, contoh: data dengan format tabel.

No	Kategori	Harga satuan	Paket
1	Tiket Masuk Objek Wisata	Rp30.000	Rp200.000
2	Rafting 5 km/2 jam	Rp75.000	
3	1x Makan Siang	Rp25.000	
4	Coffee Break	Rp15.000	
5	Peralatan Rafting	Rp30.000	
6	Free Foto Rafting	Rp50.000	

Berdasarkan tabel berikut, kita dapat dengan mudah memahami informasi atau maksud yang ingin disampaikan sekalipun data yang dimasukkan berbeda.

b) Data tidak terstruktur

Data yang memiliki struktur acak atau tidak beraturan, contoh: gambar dan teks. Data tidak harus selalu berbentuk tabel dan angka, tetapi jauh lebih luas dari itu.

c) Data semi-terstruktur

Data dengan bentuk yang tidak dikenal. Jenis data dengan tipe ini memiliki atribut terstruktur yang membuatnya tetap dapat dianalisis. Namun, pada saat yang bersamaan, data semi terstruktur ini tidak mengikuti suatu susunan tertentu seperti data tidak terstruktur. Contoh data semi-terstruktur: dokumen atau data dalam bentuk format .csv, halaman web, email, dan sejenisnya.

2. STATISTIKA DESKRIPTIF & VISUALISASI DATA

2.1 Pengantar

Statistika deskriptif adalah bagian statistika yang membahas cara-cara meringkas, menyajikan data, serta melakukan pengukuran pemusatan (*measures of location*) dan pengukuran

penyebaran (*measures of dispersion*) untuk memperoleh informasi yang lebih menarik, berguna, dan mudah dipahami pengguna. Penyajian yang dapat digunakan dalam statistik deskriptif dapat berupa, distribusi frekuensi atau presentasi grafis (histogram, pie chart, bar chart, dsb).

2.2 Ukuran Penting untuk Pengambilan Keputusan

- a) Mencari *central tendency* (kecenderungan pemusatan): Mean, Median, Modus
- b) Mencari ukuran *dispersion*: Standar Deviasi dan Varians
- c) Mencari kemiringan data (*gradien data*): Skewness dan Kurtosis

2.3 Statistika dasar menggunakan Python


Pada modul ini kita akan belajar statistika dasar menggunakan python dengan beberapa bahasan, yaitu:

Pengukuran data

- a. Ukuran Pemusatan Data: Mean, Median, Modus
- b. Ukuran Letak Data: Quartile, IQR
- c. Ukuran Penyebaran Data: Varians, Standar Deviasi

Pertama, kita buka Google Colab:

1. Akses Google Drive dan tambah extention baru di Google Drive kita dengan cara +New > More > Connect more apps > Search Colaboratory



Kita akan mencoba mempraktikkan rangkaian analisis data:

1. Menginstall Package

```
[1] ✓ 0s import pandas as pd
```

Untuk *import package* yang akan digunakan menggunakan *command import (...)* as pd. Pandas adalah library yang digunakan untuk menganalisis dan memanipulasi data dalam bentuk tabel (DataFrame). Sebelum masuk ke tahap pengembangan model, data perlu diproses dan dibersihkan. Proses ini memakan banyak waktu sebelum data dianalisis, *library* pandas membuat pemrosesan dan pembersihan data menjadi lebih mudah.

2. Mempersiapkan Dataset

Dataset yang akan kita pakai disini adalah data yang kita buat secara manual untuk keperluan latihan. Dataset ini mencakup informasi seperti nama, usia, jenis kelamin, dan nilai ujian. Setelah itu kita akan membuat dataframe dan mencoba menampilkan datasetnya.

```
# Buat dataset sederhana
data = {'Name': ['Arul', 'Feli', 'Pasha', 'Helen', 'Carlos', 'Dorian', 'Verrel', 'Jessy', 'Gini', 'Ahmad'],
        'Age': [28, 22, 35, 32, 30, 32, 30, 24, 33, 31],
        'Gender': ['Male', 'Female', 'Male', 'Female', 'Male', 'Male', 'Male', 'Female', 'Female', 'Male'],
        'Score': [85, 92, 78, 88, 76, 95, 85, 80, 90, 85]}
```

```
[3] # Membuat DataFrame
df = pd.DataFrame(data)
```

```
[4] # Menampilkan dataset
df
```

	Name	Age	Gender	Score
0	Arul	28	Male	85
1	Feli	22	Female	92
2	Pasha	35	Male	78
3	Helen	32	Female	88
4	Carlos	30	Male	76
5	Dorian	32	Male	95
6	Verrel	30	Male	85
7	Jessy	24	Female	80
8	Gini	33	Female	90
9	Ahmad	31	Male	85

3. Kita perlu memahami tipe data terlebih dahulu sebelum memulai pengukuran data.

```
# Mengecek tipe data
df.dtypes
```

	0
Name	object
Age	int64
Gender	object
Score	int64

dtype: object

Kita menggunakan `.dtypes` untuk melihat tipe data di setiap kolom. Ini membantu kita mengetahui apakah data tersebut numerik (misalnya usia, nilai) atau kategorikal (misalnya jenis kelamin). Pada latihan ini, ada tipe data `object` (name dan gender) dan `int` (age dan score). Object bisa berisi string atau teks sedangkan `int` berbentuk bilangan bulat. 64 bit artinya jumlah bilangan bulat yang bisa ditampilkan.

4. Mulai menghitung statistika deskriptif.

Statistik deskriptif membantu kita memahami karakteristik dasar dari data. Kita akan menghitung **mean, median, modus, varians, dan standar deviasi** untuk kolom numerik seperti “Age” dan “Score”.

- Mean: nilai rata-rata dari data.

```
# Rata-rata umur dan pendapatan
mean_age = df['Age'].mean()
mean_score = df['Score'].mean()

print(f"Rata-rata usia: {mean_age}")
print(f"Rata-rata nilai: {mean_score}")
```

```
Rata-rata usia: 29.7
Rata-rata nilai: 85.4
```

Artinya: Rata-rata usia orang dalam dataset adalah sekitar 30 tahun (dibulatkan), menunjukkan bahwa kebanyakan individu berada di usia akhir 20-an hingga awal 30-an. Rata-rata nilai adalah 85 (dibulatkan) menunjukkan bahwa rata-rata individu dalam dataset memiliki nilai ujian sebesar 85.

- Median: nilai tengah dari data.

```
# Nilai tengah umur dan pendapatan
median_age = df['Age'].median()
median_score = df['Score'].median()

print(f"Median usia: {median_age}")
print(f"Median nilai: {median_score}")
```

```
➡ Median usia: 30.5
   Median score: 85.0
```

Artinya: Median usia adalah 31 tahun, artinya separuh dari individu memiliki usia di bawah 31 tahun, dan separuh lainnya di atas 31 tahun. Median nilai adalah 85, artinya separuh dari individu memiliki pendapatan di bawah 85 dan separuh lainnya di atas angka ini.

- Mode (Modus): nilai yang paling sering muncul.

```
# Modus gender
mode_gender = df['Gender'].mode()[0]

print(f"Modus gender: {mode_gender}")
```

```
➡ Modus gender: Male
```

Artinya: Jenis kelamin yang paling sering muncul adalah male. Ini menunjukkan bahwa mayoritas dalam dataset ini adalah laki-laki.

- Variance (variansi): mengukur penyebaran data dari rata-rata.

```
# Variansi umur dan pendapatan
var_age = df['Age'].var()
var_score = df['Score'].var()

print(f"Variansi usia: {var_age}")
print(f"Variansi nilai: {var_score}")
```

```
➡ Variansi usia: 16.233333333333334
   Variansi nilai: 37.37777777777779
```

Apa itu varians dan mengapa diperlukan dalam analisa statistika deskriptif?

Varians termasuk dalam ukuran penyebaran data. Kita mau melihat seberapa jauh rata-rata jarak kuadrat antara nilai-nilai data dan **mean** atau nilai rata-rata. Semakin besar ukuran varians nya maka data semakin menyebar atau bervariasi. Dalam latihan ini, dapat diinterpretasikan variansi usia yang sebesar 16.233 berarti bahwa rata-rata penyimpangan umur dari nilai rata-rata umur pada dataset ini cukup kecil, (ada perbedaan dalam umur tapi tidak sangat jauh antara satu sama lain). Variansi nilai sebesar 37.377 menunjukkan bahwa sebaran nilai ujian cenderung terbilang kecil hingga sedang. Ini

menandakan bahwa nilai-nilai siswa cukup seragam dan tidak terlalu menyebar jauh dari nilai rata-rata.

- Standar Deviasi: akar kuadrat dari variansi, memberikan informasi tentang seberapa menyebar data tersebut dari rata-rata

```
# Standar deviasi umur dan pendapatan
std_age = df['Age'].std()
std_score = df['Score'].std()

print(f"Standar deviasi usia: {std_age}")
print(f"Standar deviasi nilai: {std_score}")
```

```
➡ Standar deviasi usia: 4.029061098237818
   Standar deviasi nilai: 6.113736809658867
```

Apa itu standar deviasi dan mengapa penting untuk mengetahui standar deviasi dalam sebuah analisa statistika data?

Standar deviasi adalah akar kuadrat dari variansi dan ukuran ini menunjukkan seberapa jauh nilai-nilai data cenderung menyebar dari mean. Standar deviasi adalah akar kuadrat dari variansi, jadi dia memberikan ukuran penyebaran data dalam satuan yang sama dengan data aslinya. Dalam latihan ini, dapat diinterpretasikan bahwa

- 1) Standar deviasi usia 4 (dibulatkan) tahun berarti umur rata-rata individu dalam data ini bervariasi sekitar 4 tahun dari rata-ratanya. Penyimpangan ini menunjukkan adanya sedikit perbedaan umur antar individu, tetapi tidak terlalu besar.
- 2) Standar deviasi nilai 6.113 menunjukkan bahwa penyebaran nilai sekitar 6.113 dari rata-rata nilai dalam dataset ini. Artinya standar deviasi nilai ujian cukup rapat dan terkonsentrasi. Tidak ada kesenjangan yang sangat besar antara siswa berprestasi tinggi dan rendah dalam kelompok mayoritas ini.

- Analisis Kuartil dan IQR

```
# Menghitung kuartil dan IQR
Q1 = df['Score'].quantile(0.25)
Q3 = df['Score'].quantile(0.75)
IQR = Q3 - Q1

print(f"Kuartil pertama (Q1) nilai: {Q1}")
print(f"Kuartil ketiga (Q3) nilai: {Q3}")
print(f"IQR nilai: {IQR}")
```

```
➡ Kuartil pertama (Q1) nilai: 81.25
   Kuartil ketiga (Q3) nilai: 89.5
   IQR nilai: 8.25
```


Kuartil membagi data menjadi empat bagian yang sama. IQR digunakan untuk mengukur rentang antar kuartil, yang menunjukkan seberapa menyebar data di sekitar median. Penjelasan pada code:

- **Q1** adalah kuartil pertama (25% dari data lebih kecil dari nilai ini)—batas bawah
- **Q3** adalah kuartil ketiga (75% dari data lebih kecil dari nilai ini)—batas atas
- **IQR** adalah perbedaan antara Q3 dan Q1, digunakan untuk mendeteksi pencilan (outliers) dalam data.

Dalam latihan ini dapat diinterpretasikan bahwa:

1. Kuartil pertama (Q1) adalah nilai yang memisahkan 25% data terbawah dari sisanya. Dalam kasus ini, 25% dari orang-orang memiliki nilai di bawah atau sama dengan 81.25. Ini berarti bahwa pendapatan 81.25 bisa dianggap sebagai batas rendah dalam distribusi nilai ujian.
2. Kuartil ketiga (Q3) adalah nilai yang memisahkan 75% dari data terbawah dari 25% data teratas. Jadi, 75% dari orang-orang memiliki nilai di bawah atau sama dengan 89.5, dan hanya 25% orang yang nilainya lebih besar dari angka tersebut.
3. IQR sebesar \$36.5 berarti pendapatan pada 50% tengah data tersebar dalam rentang 8.25, yang menunjukkan adanya variasi pendapatan yang cukup besar di tengah-tengah distribusi.

- Merangkum hasil perhitungan statistik deskriptif

	Age	Score
count	10.000000	10.000000
mean	29.700000	85.400000
std	4.029061	6.113737
min	22.000000	76.000000
25%	28.500000	81.250000
50%	30.500000	85.000000
75%	32.000000	89.500000
max	35.000000	95.000000

Kita bisa merangkum statistik deskriptif untuk semua kolom numerik dalam satu perintah menggunakan `df.describe()`, ini akan menampilkan ringkasan seperti mean, standar deviasi, minimum, maksimum, dan kuartil secara otomatis untuk kolom numerik.

2.4 Visualisasi data menggunakan Python

Pada modul ini kita akan belajar visualisasi data menggunakan python dengan beberapa bahasan, yaitu:

Penyajian data

- a. Ukuran Pemusatan Data
- b. Ukuran Letak Data
- c. Ukuran Penyebaran Data

1. Menginstall library yang dibutuhkan (matplotlib dan seaborn)

```
[14] # Install matplotlib dan seaborn (jika belum terinstall)
!pip install matplotlib seaborn
```

2. Mengimport kedua library tersebut

```
[15] # Import kedua library tersebut
import matplotlib.pyplot as plt
import seaborn as sns
```

Mengapa menggunakan matplotlib dan seaborn?

Kedua library ini berfungsi untuk menampilkan visualisasi data. Keduanya menyediakan banyak fungsi kustomisasi seperti pengaturan sumbu, label, warna, dan gaya. Bisa digunakan untuk membuat berbagai macam grafik seperti line chart, bar chart, scatter plot, histogram, dan lain-lain.

3. Mulai melakukan penyajian data

- Histogram (distribusi data)


```
# Membuat histogram untuk kolom 'Score'
plt.hist(df['Score'], bins=5, color='skyblue', edgecolor='black')
plt.title('Score Distribution')
plt.xlabel('Score')
plt.ylabel('Frequency')
plt.show()
```

Penjelasan code:

- **plt.hist()** membuat histogram.
- **bins** menentukan berapa banyak bar yang ingin ditampilkan.
- **color** dan **edgecolor** digunakan untuk mengatur warna grafik.

Kita bisa mengubah poin-poin ini apabila ingin mengatur gaya visualisasi yang mau ditampilkan.

Hasil:



Interpretasi: histogram ini digunakan untuk melihat distribusi frekuensi dari variabel numerik, seperti nilai atau usia. Terdapat sebagian besar individu dalam dataset memiliki nilai yang berkisar dari yang terendah yaitu 76-79 (diraih 2 peserta) dan yang tertinggi yaitu 92-95 (diraih 2 peserta). **Konsentrasi pendapatan ada di kisaran 83-87.**

- Scatterplot


```
# Scatterplot untuk melihat hubungan antara 'Age' dan 'Score'  
sns.scatterplot(x='Age', y='Score', data=df, hue='Gender', style='Gender', palette='coolwarm')  
plt.title('Age vs Score')  
plt.show()
```

(Bagian code palette yang terpotong itu: palette='coolwarm') jangan lupa diberi tanda kurung di paling belakang.

Penjelasan code:

- **sns.scatterplot()** digunakan untuk membuat scatterplot.
- **hue** dan **style** menambahkan variasi dalam visualisasi berdasarkan kategori, misalnya jenis kelamin.
- **palette** mengatur skema warna.

Hasil:



Interpretasi: Scatterplot ini digunakan untuk melihat hubungan antara dua variabel numerik, seperti usia dan pendapatan. Secara umum karena data yang digunakan sedikit, tidak terlihat tren yang sangat jelas antara usia dan nilai ujian, ada beberapa individu dengan usia yang lebih muda namun meraih nilai yang lebih tinggi, dan sebaliknya. Begitu pula hubungan nilai berdasarkan gender tetapi secara sekilas dapat dilihat bahwa individu perempuan dengan usia 22 tahun memiliki pendapatan yang lebih tinggi dibandingkan dengan individu laki-laki dengan usia yang sama.

Berdasarkan visualisasi data yang ada, tidak dapat disimpulkan secara pasti hubungan antara usia dan nilai ujian, serta pengaruh gender terhadap nilai.


- Bar chart

```
# Bar chart untuk melihat rata-rata nilai berdasarkan gender
sns.barplot(x='Gender', y='Score', data=df, palette='viridis')
plt.title('Average Score by Gender')
plt.show()
```

Penjelasan:

- **sns.barplot()** digunakan untuk membuat bar chart.

Hasil:




Interpretasi: Bar chart ini digunakan untuk melihat perbandingan antar kategori, seperti dalam grafik ini akan menunjukkan rata-rata nilai ujian untuk setiap kategori Gender. Bar chart menunjukkan rata-rata nilai ujian antara dua kelompok jenis kelamin. Pada grafik ini, terlihat bahwa perempuan memiliki nilai rata-rata yang lebih tinggi dibandingkan dengan laki-laki. Rata-rata nilai ujian perempuan berada di sekitar 90, sedangkan laki-laki berada di sekitar 85.

Ada perbedaan yang jelas dalam nilai antara laki-laki dan perempuan dalam dataset ini, dengan perempuan memiliki rata-rata nilai yang lebih tinggi.

- Line chart

```
# Contoh sederhana line chart untuk score
plt.plot(df['Name'], df['Score'], marker='o', linestyle='-')
plt.title('Score Over Time')
plt.xlabel('Name')
plt.ylabel('Score')
plt.show()
```

Hasil:




Interpretasi: Line chart cocok untuk melihat tren data yang berurutan, misalnya pendapatan atau usia berdasarkan urutan waktu (time series). Tipe visualisasi line chart sebetulnya lebih banyak dipakai untuk melihat **tren data dari waktu ke waktu (time series)** seperti harga saham atau pendapatan bulanan. Pada latihan ini hanya dicontohkan saja bagaimana memvisualisasikan menggunakan line chart.

- Boxplot

```
# Boxplot untuk pendapatan berdasarkan gender
sns.boxplot(x='Gender', y='Score', data=df, palette='Set2')
plt.title('Boxplot of Score by Gender')
plt.show()
```

Hasil:



Penjelasan dan cara membaca: Boxplot digunakan untuk melihat **distribusi data dan mendeteksi pencilan (outliers)**. Grafik ini menampilkan **median, kuartil**, dan pencilan secara visual. **Garis di tengah kotak** adalah **median** (nilai tengah). **Kotak** mewakili rentang antar kuartil (Q1 dan Q3). **Whiskers** (garis di atas dan di bawah kotak) menunjukkan rentang data tanpa pencilan. **Titik di luar whiskers** adalah **pencilan** (nilai yang jauh dari mayoritas data). Dalam boxplot **nilai ujian berdasarkan jenis kelamin**, jika whiskers lebih panjang untuk satu kelompok, itu menunjukkan bahwa distribusi nilai lebih bervariasi untuk kelompok tersebut. Misalnya, jika kotak dan whiskers untuk perempuan lebih panjang, berarti nilai perempuan lebih bervariasi daripada laki-laki. Jika ada titik di luar whiskers seperti pada kelompok laki-laki, ini menunjukkan adanya pencilan dalam pendapatan kelompok tersebut.

Interpretasi:


- Untuk laki-laki, rentang nilai berkisar antara sekitar 75.5 hingga 95, dengan median nilai berada di sekitar 82.5.
- Untuk perempuan, rentang nilai lebih tinggi, berkisar antara 80 hingga 91, dengan median di sekitar 88.5.

Distribusi nilai perempuan lebih tinggi daripada laki-laki, dengan nilai minimum laki-laki lebih rendah dari nilai perempuan.

- Pairplot

```
# Pairplot untuk melihat hubungan antar variabel numerik
sns.pairplot(df, hue='Gender', palette='coolwarm')
plt.show()
```

Hasil:



Penjelasan dan cara membaca: Dalam pairplot variabel usia, nilai, dan jenis kelamin, kita bisa melihat hubungan antar variabel. Misalnya, jika scatterplot antara usia dan nilai menunjukkan pola garis naik ke kanan, ini menunjukkan bahwa semakin tua seseorang, semakin besar kemungkinan mereka memiliki pendapatan yang lebih tinggi. Jika ada beberapa grafik yang tidak menunjukkan pola, maka variabel tersebut mungkin tidak berkorelasi kuat.

Interpretasi: Pada bagian usia dan nilai, titik-titik tampak tersebar secara acak, tidak membentuk pola garis lurus naik atau turun. Ini menandakan tidak ada korelasi yang kuat antara usia dan nilai. Artinya, bertambahnya usia tidak berarti nilai akan naik ataupun turun dalam dataset ini. Terlihat jelas ada dua kelompok data, kelompok perempuan (oranye) yang cenderung berada di sisi usia lebih muda, dan kelompok laki-laki (biru) yang cenderung di sisi usia lebih tua.

3. REGRESI LINEAR

3.1 PENGENALAN REGRESI

Regresi adalah sebuah fungsi yang digunakan untuk melihat pengaruh antara dua atau lebih variabel, dengan cara melihat hubungan antara variabel yang ingin diramalkan (Dependent variabel) dengan variabel lain (Independent variabel).

3.3.1 Mengenal Regresi Linear Sederhana

Regresi Linear adalah sebuah teknik prediksi yang diasumsikan bahwa terdapat hubungan antaravariabel yang ingin diramalkan (variabel tak bebas) dengan variabel lain (variabel bebas). Biasanya digunakan untuk memprediksi kapasitas distribusi dimasa depan, inflasi, harga saham, CPI (Customer Price Indeks), dan yang lainnya.

Contoh Penggunaan Analisis Regresi Linear Sederhana dalam Produksi antara lain :

1. Hubungan antara Lamanya Kerusakan Mesin dengan Kualitas Produk yang dihasilkan
2. Hubungan Jumlah Pekerja dengan Output yang diproduksi
3. Hubungan antara suhu ruangan dengan Cacat Produksi yang dihasilkan.
 - Pengukuran Linear Regression, yang digunakan untuk memprediksi:
 - $y = mx + c$ (m adalah slope/intercept, c constant). Atau $Y = a + bX$

$$Y = a + bX$$

where:

Y = Dependent Variable

X = Independent Variable

a = constant

b = regression coefficient(skew);

3.3.2 Tipe Data yang Harus Diketahui dalam Pemrograman

Tipe Data	Contoh	Penjelasan
Boolean	True atau False	Menyatakan benar True yang bernilai 1, atau salah False yang bernilai 0

String	"Ayo belajar Python"	Menyatakan karakter/kalimat bisa berupa huruf angka, dll(diapit tanda " atau ')
Integer	25 atau 1209	Menyatakan bilangan bulat
Float	3.14 atau 0.99	Menyatakan bilangan yang mempunyai koma
List	['xyz', 786, 2.23]	Data untaian yang menyimpan berbagai tipe data dan isinya bisa diubah-ubah
Tuple	('xyz', 768, 2.23)	Data untaian yang menyimpan berbagai tipe data tapi isinya tidak bisa diubah
Dictionary	{'nama':'adi','id':2}	Data untaian yang menyimpan berbagai tipe data berupa pasangan penunjuk dan nilai

3.2 Regresi Linear Sederhana Menggunakan Python

1. Menginstal library python yang akan digunakan package linear regresian dan tools train test split.

```
[26]
✓ 0s
import pandas as pd
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
```

2. Mengambil dataset .csv yang telah didownload sebelumnya

```
# Upload file
from google.colab import files
uploaded = files.upload()

Choose Files data_nilai.csv
data_nilai.csv(text/csv) - 106 bytes, last modified: 9/24/2025 - 100% done
saving data_nilai.csv to data_nilai.csv
```

3. Melihat informasi data kita mulai dari jumlah data, tipe data, memory yang digunakan

```
datalab = pd.read_csv('datanilai_praktikum.csv', usecols=['Nilai Ujian', 'Jam Belajar'])
datalab.head()
```



	Jam Belajar	Nilai Ujian
0	1	52
1	2	56
2	3	59
3	4	62
4	5	65

datalab.info()

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20 entries, 0 to 19
Data columns (total 2 columns):
#   Column      Non-Null Count  Dtype
---  -
0   Jam Belajar  20 non-null    int64
1   Nilai Ujian  20 non-null    int64
dtypes: int64(2)
memory usage: 452.0 bytes
```

4. Melihat isi kolom Nilai Ujian di datalab beserta keterangan type data

```
print(datalab ['Nilai Ujian'])
```

```
0    85
1    95
2    60
3    75
4    55
5    88
6    68
7    82
Name: Nilai Ujian, dtype: int64
```

5. Melihat statistical description dari data mulai dari mean, kuartil, standard deviation

	Jam Belajar	Nilai Ujian
count	20.00000	20.00000
mean	10.50000	78.65000
std	5.91608	14.87589
min	1.00000	52.00000
25%	5.75000	67.25000
50%	10.50000	80.00000
75%	15.25000	91.50000
max	20.00000	100.00000

- Count: Menunjukkan jumlah Total Data yaitu sebanyak 20 data
- Mean: Rata-rata jam belajar 10.5 jam dengan rata-rata nilai ujian 79
- Std: Mengukur sebaran data variasi jam belajar 6 dengan variasi nilai ujian sebanyak 14.87
- Min: Nilai minimum pada jam belajar sebesar 1 jam dengan nilai ujian sebesar 52.
- Q1 (25%): Menunjukkan dengan rata-rata jam belajar sebesar 6 jam mendapatkan rata-rata nilai ujian sebesar 67.
- Q2 (50%)/Median: Menunjukkan dengan rata-rata jam belajar sebanyak 10 jam mendapatkan rata-rata nilai ujian sebesar 80.
- Q3 (75%): Menunjukkan dengan jam belajar sebanyak 15 jam mendapatkan rata-rata nilai ujian sebesar 91.5.
- Max: Nilai Maksimum dengan jam belajar rata-rata 20 jam mendapatkan rata-rata nilai ujian sebesar 100.

6. Mencari dan menangani missing values. Ternyata data kita tidak ada missing values.

```
datalab.isnull().sum()
```

```
0
Nilai Ujian    0
Jam Belajar    0
dtype: int64
```

Dari data tidak terdapat data yang hilang dengan data bertipe int64. Jika tidak ditemukan adanya missing values, dan menunjukkan type data adalah integer. Maka proses perhitungan Linear Regression bisa kita mulai.

7. Buat variabel (x) dan (y)

```
#Pertama, buat variabel x dan y.  
x = datalab['Jam Belajar'].values.reshape(-1,1)  
y = datalab['Nilai Ujian'].values.reshape(-1,1)
```

8. Split data kita menjadi training and testing dengan porsi 80:20.

```
[33] ✓ 0s x_train, x_test, y_train, y_test = train_test_split(x, y, shuffle = True, test_size = 0.2, random_state = 42)
```

Fungsi untuk membagi data dengan porsi 80:20 berarti membagi dataset menjadi dua bagian: 80% untuk pelatihan (training) dan 20% untuk pengujian (testing).

9. Set Object Linear Regresi dan Training model menggunakan training data yang sudah displit sebelumnya.

```
lin_reg.fit(x_train, y_train)  
print(lin_reg.coef_)  
print(lin_reg.intercept_)  
[[2.42316393]  
 [53.54954004]]
```

- Koefisien: Untuk setiap tambahan satu jam belajar, nilai ujian diperkirakan meningkatkan sebanyak 2.4
- Intercept: Menunjukkan bahwa jika seseorang memiliki nol jam belajar, maka nilai ujian yang diperkirakan adalah 53.54

10. Akurasi model Linear Regression


```
lin_reg.score(x_test, y_test)  
0.9858747911669078
```

Baca: tingkat akurasi menunjukan 98%. Artinya model regresi yang digunakan sangat baik atau variabel x dan y yang diuji menunjukkan korelasi yang baik.

11. Visualisasi Regression Line menggunakan data testing

```
y_prediksi = lin_reg.predict(x_test)  
plt.scatter(x_test, y_test)  
plt.plot(x_test, y_prediksi, c='r')  
plt.xlabel('Jam Belajar')  
plt.ylabel('Nilai Ujian')  
plt.title('Plot')
```

Hasil:



- Titik-titik : Menunjukkan jam belajar dengan nilai ujian yang di dapatkan
- Garis Regresi : Mencerminkan Hubungan antara gaji tahunan dengan skor pengeluaran yang didapatkan. Artinya semakin banyak jam belajar, semakin tinggi nilai ujian yang didapatkan.

12. Membuat Nilai Prediksi

```
lin_reg.predict([[20]])
array([[102.01281858]])
```

Baca : Prediksi Nilai Ujian dengan Jam Belajar 20 jam. Prediksi Nilai Ujian yang akan diraih oleh orang yang memiliki jam belajar 20 jam berdasarkan data adalah 100.

3.3 Regresi Linear Berganda

Kita akan menguji variabel x yang lain yaitu jumlah absen. Menggunakan regresi linear berganda kita akan mengetahui apakah jam belajar dan jumlah absen mempengaruhi nilai ujian yang diraih oleh peserta.

1. Melihat informasi data kita mulai dari jumlah data, tipe data, memory yang digunakan.

```
datalab = pd.read_csv('datanilai_praktikum.csv', usecols=['Nilai Ujian', 'Jam Belajar', 'Jumlah Absen'])
datalab.head()
```

	Jam Belajar	Jumlah Absen	Nilai Ujian
0	1	9	52
1	2	8	56
2	3	8	59
3	4	7	62
4	5	6	65

2. Buat variabel (x) dan (y)

```
x = datalab[['Jam Belajar', 'Jumlah Absen']]
y = datalab['Nilai Ujian']
```

3. Split data kita menjadi training and testing dengan porsi 80:20.

```
x_train, x_test, y_train, y_test = train_test_split(x, y, shuffle = True, test_size = 0.2, random_state = 42)
```

4. Set Object Linear Regresi dan Training model menggunakan training data yang sudah displit sebelumnya.

```
lin_reg = LinearRegression()
lin_reg.fit(x_train, y_train)
print(lin_reg.coef_)
print(lin_reg.intercept_)

[ 1.43511066 -2.12927565]
71.81841046277664
```

- Koefisien:
 - a. Untuk setiap penambahan 1 jam belajar, nilai ujian diprediksi akan naik sebesar 1.44 poin, dengan asumsi jumlah absen tetap.
 - b. Untuk setiap penambahan 1 kali absen, nilai ujian diprediksi akan turun sebesar 2.13 poin, dengan asumsi jam belajar tetap.
- Intercept: Menunjukkan bahwa jika seseorang memiliki nol jam belajar dan nol jumlah absen maka nilai ujian yang diperkirakan sebesar 71.81.

5. Akurasi model linear regression

```
lin_reg.score(x_test, y_test)

0.9939790708831261
```

Baca: tingkat akurasi menunjukkan 99%. Artinya model regresi yang digunakan sangat baik atau variabel X1, X2, dan y yang diuji menunjukkan korelasi yang baik. Variabel y (nilai ujian) dipengaruhi oleh faktor-faktor lain selain X1 (jam belajar) dan X2 (jumlah absen).

6. Mempersiapkan data prediksi sebelum divisualisasikan

```
lin_reg.predict([[20, 10]])

/usr/local/lib/python3.12/dist-packages/sklearn/utils
warnings.warn(
array([79.2278672])
```

Baca: Prediksi Nilai Ujian dengan Jam Belajar 20 jam dan Jumlah Absen 10 Kali. Prediksi Nilai Ujian yang akan diraih oleh orang yang memiliki jam belajar 20 jam dan jumlah absen 10 kali berdasarkan data adalah 79.

7. Import matplotlib notebook untuk membantu membaca visualisasi 3D

```
[44] %matplotlib notebook
✓ Os
```

Matplotlib notebook harus diimport sebelum mengimport library yang dibutuhkan untuk visualisasi.

8. Import library

```
[45]
✓ 0s
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D
from sklearn.linear_model import LinearRegression
```

9. Merancang letak nilai aktual dari dataframe dengan nilai prediksi di visualisasi

```
# 1. Buat kanvas 3D
fig = plt.figure(figsize=(12, 9))
ax = fig.add_subplot(111, projection='3d')

# 2. Tampilkan data asli (scatter plot)
ax.scatter3D(x['Jam Belajar'], x['Jumlah Absen'], y, color='#007ACC', label='Nilai Ujian')

# 3. Buat grid untuk bidang regresi
x_surf = np.linspace(x['Jam Belajar'].min(), x['Jam Belajar'].max(), 20)
y_surf = np.linspace(x['Jumlah Absen'].min(), x['Jumlah Absen'].max(), 20)
x_surf, y_surf = np.meshgrid(x_surf, y_surf)

# 4. Prediksi nilai z untuk setiap titik di grid
z_surf = lin_reg.predict(pd.DataFrame({'Jam Belajar': x_surf.ravel(), 'Jumlah Absen': y_surf.ravel()}))
z_surf = z_surf.reshape(x_surf.shape)

# 5. Gambar bidang regresi (surface plot)
ax.plot_surface(x_surf, y_surf, z_surf, color='red', alpha=0.4)

# 6. Pengaturan akhir plot
ax.set_xlabel('Jam Belajar')
ax.set_ylabel('Jumlah Absen')
ax.set_zlabel('Nilai Ujian')
ax.set_title('Visualisasi Regresi Linear Berganda 3D', fontsize=16)
plt.show()
```

10. Visualisasi 3D Model Regresi Linear Berganda

```
import plotly.graph_objects as go
# Buat trace untuk scatter plot 3D data asli
trace1 = go.Scatter3d(
    x=x['Jam Belajar'],
    y=x['Jumlah Absen'],
    z=y,
    mode='markers',
    name='Data Asli',
    marker=dict(size=5)
)


# Buat trace untuk surface plot (bidang regresi)
trace2 = go.Surface(
    x=x_surf,
    y=y_surf,
    z=z_surf,
    colorscale='Reds',
    opacity=0.5,
    name='Bidang Regresi'
)

# Gabungkan dalam satu gambar
fig = go.Figure(data=[trace1, trace2])

# Pengaturan layout
fig.update_layout(
    title='Visualisasi 3D Regresi dengan Plotly',
    scene=dict(
        xaxis_title='Jam Belajar',
        yaxis_title='Jumlah Absen',
        zaxis_title='Nilai Ujian'
    )
)

fig.show()
```

Hasil:



Grafik 3D ini adalah cara yang sangat baik untuk memvisualisasikan keberhasilan model regresi kita. Grafik ini membuktikan bahwa hubungan antara jam belajar, jumlah absen, dan nilai ujian dalam data sangatlah kuat dan linear, sehingga dapat diprediksi dengan sangat baik oleh model regresi linear.

Interpretasi: Permukaan merah transparan itu adalah bidang regresi, representasi visual dari formula prediksi model kita. Kemiringan bidang ini menunjukkan hubungan antar variabel:

- Nilai Ujian vs. Jam Belajar: Jika kita mengikuti sumbu "Jam Belajar" dari nilai rendah ke tinggi (misalnya dari 5 ke 20), kita akan melihat bidang merah ini naik. Ini secara

visual mengonfirmasi bahwa semakin banyak jam belajar, semakin tinggi prediksi nilai ujian.

- Nilai Ujian vs. Jumlah Absen: Jika kita mengikuti sumbu "Jumlah Absen" dari nilai rendah ke tinggi (misalnya dari 0 ke 8), kita akan melihat bidang merah ini turun. Ini menunjukkan bahwa semakin banyak absen, semakin rendah prediksi nilai ujian.

Tugas Pertemuan 1

1. Anda diminta untuk mengeksplorasi analisa statistika deskriptif dan visualisasi data dan/atau analisis regresi linear sederhana dan berganda menggunakan dataset apapun.
 - **Kelompok ganjil** mengerjakan statistika deskriptif dan visualisasi data. Kalian dapat membuat dataset kalian sendiri di Excel atau Spreadsheet dan diunduh menjadi file .csv (bukan file .xlsx). Pastikan dataset kalian memiliki 2 tipe data INT64 dan 1 tipe data object/string agar bisa dianalisis statistika deskriptif. Contoh datanya bisa berupa data penjualan produk, gaji dan pengalaman kerja, dan lain-lain sesuai dengan kreativitasan masing-masing. **Minimal jumlah data pada dataset 10** agar visualisasi data bisa diinterpretasikan.
 - **Kelompok genap** mengerjakan regresi linear sederhana dan berganda menggunakan dataset yang kalian cari di kaggle atau sumber lainnya. Pastikan file dalam .csv juga lalu upload. **Minimal jumlah data pada dataset 20** agar analisa regresi lebih akurat. Cari data dengan variabel lebih dari 2-3 (satu variabel Y, dua variabel X) untuk pengerjaan regresi linear.
2. Silakan melakukan eksplorasi analisa statistika deskriptif dan visualisasi data/regresi linear sederhana dan berganda, minimal 2 macam ukuran dan 2 macam visualisasi.
3. Buatlah presentasi tugas kalian menggunakan PPT. Masukkan screen shot code, hasil output pada colab, dan interpretasi tugas kalian.
4. **Dalam format ZIP, *compile* file presentasi dalam format pdf, file colab dalam format ipnyb (yang sudah di-run), beserta file dataset yang telah kalian buat/cari dalam format csv** pada form yang disediakan asprak.
5. Pengumpulan maksimal 2 hari sebelum pelajaran Big Data minggu berikutnya.
6. **Kelompok tercepat akan mendapat poin tambahan.**
7. **Dilarang copas hasil pekerjaan kelompok lain.**
8. File dikumpulkan dalam **format ZIP**.

SELAMAT MENGERJAKAN!